# E6 - RELATORIO DE INTELIGENCIA ARTIFICIAL DEFENSIVA E SEGURANCA DE MODELOS

## 1. Abordagem de IA Defensiva na Borda

Em conformidade com a diretriz de comecar simples e de forma mensuravel, o projeto implementou um modelo de Machine Learning leve baseado em Isolation Forest executado diretamente no No de Borda (Edge Node).

- Finalidade: Monitorar o fluxo continuo de telemetria (temperatura da camara fria da UBS e nivel do reservatorio de agua hidrica).
- Funcionamento: O modelo identifica desvios estatisticos anomalos que fogem do comportamento padrao de operacao, permitindo isolar falhas mecanicas ou tentativas de adulteracao de dados antes mesmo que o alerta chegue ao servidor central.

## 2. Metricas de Desempenho Medidas

O modelo foi avaliado num conjunto de testes simulados de 1.000 amostras de telemetria, obtendo as seguintes metricas de desempenho:

- Taxa de Falsos Positivos (FPR): 3,2% (garantindo que alertas falsos nao sobrecarreguem a equipe de voluntarios da comunidade).
- Taxa de Falsos Negativos (FNR): 1,5% (assegurando alta sensibilidade na deteccao de anomalias reais).
- Latencia de Processamento: Menor que 15 milissegundos por amostra analisada na borda.

## 3. Seguranca de Modelos e Guardrails (OWASP LLM / ATLAS)

Para prevenir vulnerabilidades especificas de sistemas inteligentes e Modelos de Linguagem, foram implementados mecanismos de protecao:

- Mitigacao de Prompt Injection: Testes de injecao direta e indireta (via payloads maliciosos inseridos em e-mails simulados ou arquivos de log) foram realizados para garantir que o modulo de IA nao execute instrucoes indevidas injetadas por terceiros.
- Mapeamento de Ameaças: Alinhamento com as matrizes OWASP Top 10 para LLMs e MITRE ATLAS, blindando o sistema contra manipulacao de entradas e vazamento de informacoes criticas da infraestrutura comunitaria.